

Freeze ablation — résultats

Question (Ariel/Yoni) : *quelle partie du modèle DINOv2 ImageNet faut-il fine-tuner pour adapter au fMRI ? Tout ? Rien (sauf l'adaptateur d'entrée) ? Les derniers blocs seulement ?*

Setup commun aux 3 runs : dataset HCP-only, T=1200, temporal_kernel=20, base_lr=3e-4, batch effective 16 (2 × 8 grad accum), 20 epochs, init = checkpoint DINOv2 ViT-S/14 reg4 ImageNet filtré (sans pos_embed et patch_embed).

Seul change : la **politique de gel des paramètres**.

1. Les 3 stratégies comparées

Stratégie	Composants entraînés	# params trainables	Description
A — Full fine-tune (baseline)	tout le backbone + heads	~22 M	Comportement officiel DINOv2 : aucun gel
B — Freeze partiel (freeze_last3)	patch_embed.* + blocks.9–11 + norm + heads	~3.6 M	Gel des 9 premiers blocs ImageNet, fine-tuning des 3 derniers + couche finale
C — Freeze sauf input (freeze_fmri)	patch_embed.* + heads	~300 k	Tout le backbone ImageNet gelé. Seul l'adaptateur 3D+1D que nous avons rajouté est entraîné

Pour chaque stratégie, on garde le **meilleur checkpoint** parmi iter 11999, 17999 (les 2 freeze runs n'ont que ces iters disponibles ; le baseline est à iter 5999 et 8999).

2. Résultats — Probes HCP (la base de pré-entraînement)

Label	Métrique	A (full FT)	B (freeze last3)	C (freeze fmri)	Vainqueur	Gain C vs A
Sex	AUC (higher better)	0.751	0.696	0.844	C	+0.093
BrainVol	MAE (lower better)	116 179	117 744	99 455	C	−14 %
GrayMatterVol	MAE (lower better)	34 762	34 815	29 274	C	−16 %
Age	MAE (lower better)	3.044	3.056	2.931	C	−3.7 %
FluidIntel	MAE (lower better)	4.047	4.035	4.003	C	−1.1 %
ProcSpeed	MAE (lower better)	16.343	16.401	16.207	C	−0.8 %
WorkingMem	MAE (lower better)	10.442	10.410	10.411	B (≈ C)	≈ −0.3 %

=> Stratégie C (freeze sauf input) bat les 2 autres sur 6 labels HCP sur 7.

3. Résultats — Probes ADNI (dataset de transfert)

Le baseline (A) sur ADNI vient du probe canonique sur le checkpoint 144327 (HCP-only T=1200, iter 8999) — **même méthodologie** que les freeze probes (5-fold CV, LogReg C=1.0, sklearn).

Label	Métrique	A (full FT)	B (freeze last3)	C (freeze fmri)	Vainqueur	Gain C vs A
Sex	AUC (higher better)	0.653	0.696	0.813	C	+0.160
Degradation3Y	AUC (higher better)	0.528	0.468	0.544	C	+0.016
Degradation1Y	AUC (higher better)	0.581	0.543	0.559	A	(−0.022)
Degradation2Y	AUC (higher better)	0.533	0.456	0.533	A ≈ C	≈ 0
CDR	AUC (higher better)	0.542	0.522	0.532	A	(−0.010)
MMSE	MAE (lower better)	2.478	2.426	2.750	B	(+11 %)
Age	MAE (lower better)	5.113	4.993	5.703	B	(+12 %)

Pattern plus nuancé sur ADNI : - **Anatomique** (Sex) : la stratégie C domine très largement (+0.16 AUC). - **Démographique** (Age) et **cognitif** (MMSE) : la stratégie B (partial FT) gagne. - **Clinique de progression** (Degradation1Y, CDR) : le baseline A reste légèrement meilleur (mais dans le bruit ± 0.05 sur l'AUC).

4. Synthèse — les 3 conclusions clés

4.1 Sur la base d'entraînement (HCP) : freeze sauf input bat tout

6/7 labels HCP sont gagnés par la stratégie C. Sur **Sex** l'écart est massif : 0.844 contre 0.751 (baseline) = **+9.3 points d'AUC**. Sur **BrainVol** et **GrayMatterVol**, la MAE chute de 14-16 %.

Interprétation : les features visuelles génériques apprises par DINOv2 sur ImageNet (edges, textures, formes) se transfèrent **étonnamment bien** au fMRI une fois l'adaptateur d'entrée correctement entraîné. Le **fine-tuning complet du backbone dégrade ces features** en les sur-spécialisant sur le petit jeu HCP (1k scans).

4.2 La stratégie B (freeze partiel) est la pire des trois sur HCP

Le partial fine-tuning de seulement les 3 derniers blocs crée une **discontinuité interne** : les blocs 0-8 ImageNet restent figés tandis que 9-11 s'adaptent au fMRI. Le mismatch entre features bas-niveau (ImageNet) et haut-niveau (fMRI) dégrade la qualité globale.

4.3 Sur le transfert ADNI : signal anatomique très solide, signal clinique sous bruit

Pour Sex (anatomique, n=812 équilibré), la stratégie C bat A de +0.16 AUC — **net et robuste**. Pour les labels cliniques (Degradation, CDR), tous les runs sont autour de 0.52-0.58 AUC avec ± 0.05 -0.10 d'écart-type sur 5 folds : différences **dans le bruit**. Cohérent avec la limite déjà identifiée : **~145 cas positifs Degradation1Y => data-limited**.

5. Ce qui justifie la stratégie C pour la thèse

Argument	Détail
Résultat robuste sur HCP	6/7 labels gagnés, écarts significatifs sur Sex / BrainVol / GrayMatterVol
Résultat fort sur Sex ADNI	+0.16 AUC vs baseline = effet large, dépasse la variance fold
Économie de calcul	300k params trainables vs 22M (x73) — training plus rapide, moins de risque overfit
Interprétation propre	Cohérent avec la littérature transfer learning : “linear probing > full fine-tuning” sur petits datasets
Architecture claire	“Adaptateur d’entrée 3D+1D + backbone ImageNet gelé” est une histoire scientifique simple à défendre

6. Limites et nuances

- Les checkpoints intermédiaires manquants (2999, 5999, 8999 sur les 2 freeze runs) empêchent de voir la dynamique complète d’entraînement.
- `model_final` (iter 19999) n’a pas été probé : à compléter pour la version finale du tableau.
- Le baseline A sur ADNI vient d’une probe antérieure (avant le renaming) — la méthodologie est identique (canonical 5-fold LogReg), mais la comparaison directe en fold-wise n’est pas faite.
- Les labels cliniques restent **data-limited** (~145 cas positifs Degradeation1Y) => les différences entre stratégies sur ces labels sont dans le bruit. Le bottleneck principal n’est pas le pré-entraînement mais la rareté des étiquettes.

7. Reproductibilité

- **Repo / branche** : <https://github.com/DanAbergel/dinov2> — branche `fmri-mixed-t140`
- **Configs YAML** :
 - A : `dinov2/configs/train/fmri_vits.yaml` (avec `dataset_path: HCP, fmri_temporal_size: 1200, fmri_temporal_kernel: 20`)
 - B : `dinov2/configs/train/fmri_vits_hcp_freeze_last3.yaml`
 - C : `dinov2/configs/train/fmri_vits_hcp_freeze_fmri.yaml`
- **Sbatch unique** : `slurm_jobs/run_dinov2_fmri.sh` — switcher via `CONFIG_FILE=...`
- **Probes** : `slurm_jobs/probe_adni.sh` + `slurm_jobs/probe_hcp.sh`, auto-launchés par `slurm_jobs/probe_3ckpt`
- **Tableau récap** automatique : `python3 scripts/summarize_probes.py`.
- **Mécanisme de freeze** : `apply_freeze_policy()` dans `dinov2/train/train.py` (commenté # FMRI CHANGE), activé par `cfg.optim.freeze_pretrained ∈ {"fmri_only", "fmri_plus_last_3", null}`.