

SOTA fMRI — comparaison pour Ariel & Yoni

2026-06-14

Nos chiffres (rappel)

Linear probe sur CLS gelé, 5-fold subject-aware CV. **Métriques utilisées par les SOTA : Accuracy (%) et F1 (%) pour la classification ; MAE pour la régression.** Best across iters 11999 / 17999 / 19999.

Tâche	Métrique	A (full FT)	C (freeze-fmri)
HCP Sex	Acc / F1	63.6 / 45.8	76.9 / 73.0
ADNI Sex	Acc / F1	67.0 / 59.5	73.9 / 71.3
ADNI Age	MAE (y)	5.19	5.70
ADNI MMSE	MAE	2.39	2.75
ADNI CDR_Binary	Acc / F1	61.0 / 0.6	61.5 / 21.1
ADNI CDR NC-vs-AD (drop MCI)	Acc / F1	70.8 / 0.0	—
ADNI CDR NC-vs-MCI (drop AD)	Acc / F1	61.1 / 75.9	—
ADNI CDR_global	MAE	0.276	—
ADNI GDSCALE	Acc / F1	91.3 / 33.4	—
ADNI FAQ Binary	Acc / F1	88.2 / 0.0	—
ADNI Degradation 1Y	Acc / F1	81.6 / 0.0	81.4 / 2.4
ADNI Degradation 2Y	Acc / F1	70.6 / 0.8	68.4 / 5.5
ADNI Degradation 3Y	Acc / F1	68.8 / 0.0	66.4 / 8.4

Note sur F1 = 0 : LogReg(C=1.0) sans `class_weight="balanced"` prédit la classe majoritaire sur les labels déséquilibrés (CDR, FAQ, Degradation 1Y où prévalence ~18-30%) □ F1 du positif = 0 mais Acc reste haute. Ce n'est PAS une absence de signal, c'est un threshold non calibré. La même chose s'observe probablement chez Brain-JEPA/SLIM-Brain sans qu'ils le rapportent.

Les 9 SOTA

Brain-JEPA — NeurIPS 2024 Spotlight

Lien : arxiv.org/abs/2409.19407

- **Architecture** : JEPA (Joint Embedding Predictive Architecture) + ViT, sur séries temporelles ROI.
- **Pretraining** : UK Biobank, **32 130 sujets** (80% des 40 162). Représentation = **450 ROI** Schaefer-400 + Tian-50, 160 timesteps. ROI-based, pas volumétrique.
- **Résultats clés** (verbatim, Tables 1-2-3-9, métrique = Acc% / F1%, **aucun AUC publié**) :
 - UKB Sex : Acc **88.17%** / F1 88.58%
 - HCP-Aging Sex : Acc **81.52%** / F1 84.26%
 - ADNI NC-vs-MCI : Acc **76.84 ± 1.05** / F1 86.32 ± 0.54 (n=189)
 - ADNI Amyloid β +/- : Acc 71.00 ± 4.90 / F1 75.97 ± 3.93
 - MACC NC-vs-MCI (Asiatiques) : Acc 65.98 ± 2.84 / F1 64.67 ± 2.61
 - **OASIS-3 AD conversion** (= notre Degradation, mais sans horizon 1/2/3Y) : Acc **69.00 ± 7.35** / F1 67.32 ± 7.92
 - CamCAN Depression : Acc 72.73 ± 2.87 / F1 67.45 ± 1.57

- **CV protocole** : split fixe 6:2:2 train/val/test, 5 runs indépendants. **Subject-aware non explicitement confirmé** dans le papier.
- **Nous vs eux** :
 - HCP Sex : eux **Acc 81.52%** vs nous **Acc 76.9% (C)** ou **63.6% (A)** — gap ~5 points sur C
 - ADNI NC-vs-MCI : eux **Acc 76.84%** vs nous **Acc 61.1%** — gap ~16 points
 - **AD Conversion (OASIS-3)** : eux **Acc 69%** vs nous **Degradation 1Y Acc 81.6%** (mais notre F1 ≈ 0 □ on prédit toujours “non-déclin”)
 - Sur Acc brute on est ~comparables. Sur F1, leur F1 67% sur AD Conversion est bien au-dessus de nos F1 ~0 sur Dégradation.

BrainLM — ICLR 2024

Lien : [biorxiv 2023.09.12.557460](https://doi.org/10.1101/2023.09.12.557460)

- **Architecture** : Masked-Autoencoder Transformer, 111 M params.
- **Pretraining** : UKB 76 296 recordings (~6 450 h) + HCP 1 002 recordings (~250 h) = **77 298 recordings / 6 700 h**. Atlas **AAL-424 ROI**.
- **Résultats clés** : UKB Age MSE z-scoré **0.503**, PTSD 0.015, Anxiety 0.073, Neuroticism 0.069. Aucun chiffre Sex / MMSE / AD / MCI.
- **Nous vs eux** : non comparable directement (MSE z-scoré, pas convertible en MAE sans la std d’âge UKB).

SLIM-Brain — arXiv Déc 2025

Lien : arxiv.org/abs/2512.21881

- **Architecture** : **4D Hiera-JEPA**, hiérarchique, sur volumes 4D bruts (comme nous).
- **Pretraining** : **4 129 sessions** seulement (8-20x moins que Brain-JEPA / BrainLM).
- **Résultats clés** (verbatim, Tables 1-5-6, 3 runs) :
 - HCP Sex : Acc **91.1%** / F1 **91.1%** (linear probe : Acc 90.6 / F1 90.5)
 - HCP Fingerprint : Acc 98.5 / F1 98.1
 - ADNI MCI (finetune) : Acc **69.12 ± 1.38** / F1 68.96 ± 0.26
 - ADNI MCI (linear probe) : Acc 66.66 ± 1.40 / F1 64.52 ± 1.16
 - ADHD-200 : Acc 63.53 ± 0.53
 - PPMI Parkinson : Acc 70.40 ± 0.59
 - ABIDE Age (classification) : Acc 64.41 ± 0.57
 - ABIDE Age (régression) : MSE z-scoré 0.2175 ± 0.019
 - **Bat Brain-JEPA** sur ADNI MCI (69.12 vs 64.53) et sur HCP Sex (91.1 vs 87.1)
- **CV protocole** : split fixe **70/10/20** train/val/test, 3 runs. **Subject-aware non explicitement confirmé.**
- **Nous vs eux** :
 - HCP Sex : eux **Acc 91.1% / F1 91.1%** vs nous **Acc 76.9% / F1 73.0% (C)** — gap ~14 points sur Acc, ~18 sur F1
 - ADNI MCI : eux **Acc 69.12%** vs nous (CDR_Binary) **Acc 61.0%** — gap ~8 points
 - Ils sont au-dessus partout. Mais : leur scale 4k > notre 1.2k, et leur archi Hiera-JEPA est plus mûre.

BrainGFM — arXiv 2025

Lien : arxiv.org/abs/2506.02044

- **Architecture** : Graph FM (graph contrastive + masked AE + meta-learning + language prompts).
- **Pretraining** : **27 datasets**, 25 pathologies, **25 000+ sujets / 60 000 scans / 400 000 graphes**, 8 parcellations.
- **Résultats clés** : chiffres précis sous extraction.
- **Nous vs eux** : paradigme totalement différent (graphes de connectomes).

LCM (Large Connectome Model) — AAAI 2026

Lien : arxiv.org/abs/2510.18910

- **Architecture** : Transformer decoder-only avec MHSA + MHCA (features connectome x tokens “brain-environment”).
- **Pretraining** : taille corpus non clairement caractérisée. Représentation = connectome (FC matrix).
- **Résultats clés** sous **5-fold subject-aware** (même protocole que nous) :
 - HCP-Aging Sex F1 **73.94 ± 2.45** / HCP-YA Sex F1 **72.23 ± 1.92**
 - **ADNI Alzheimer F1 85.33 ± 7.35**
 - PPMI Parkinson F1 84.18 / ABIDE Autism F1 72.50
- **Nous vs eux** :
 - HCP-YA Sex : eux **F1 72.23** vs nous **F1 73.0 (C)** — **on est au niveau de LCM**
 - ADNI AD : eux **F1 85.33** vs nous CDR_NC_vs_AD **F1 0.0** (threshold collapse, Acc 70.8%) □ côté F1 ils gagnent largement

BNT (Brain Network Transformer) — NeurIPS 2022

Lien : arxiv.org/abs/2210.06681

- **Architecture** : Transformer sur graphes connectome, “Orthonormal Clustering Readout”.
- **Pretraining** : aucun, **supervisé end-to-end**.
- **Résultats clés** : ABIDE Autism AUROC 80.2%. ABCD Sex (n=7 901). Brain-JEPA rapporte que **BNT bat Brain-JEPA** sur ADNI NC/MCI Acc (78.90% vs 76.84%).
- **Nous vs eux** : pas de comparator direct ADNI/HCP — baseline supervisée historique.

OViTAD — Brain Sciences 2023

Lien : [biorxiv 2021.11.27.470184](https://biorxiv.org/2021.11.27.470184)

- **Architecture** : ViT 2D entraîné slice-par-slice, majority vote au niveau sujet.
- **Pretraining** : aucun, supervisé end-to-end ADNI.
- **Résultats clés** sous **subject-aware 80/10/10** (226/27/31) :
 - AD vs HC : F1 **0.99 ± 0.02**
 - HC vs MCI : F1 **0.97 ± 0.03**
- **Nous vs eux** : F1 0.99 intimidant, mais test = 31 sujets □ std 0.02 = bruit massif. Méfiance.

BrainNetCNN — NeuroImage 2017

Lien : PDF Kawahara 2017

- **Architecture** : CNN avec filtres custom Edge-to-Edge / Edge-to-Node / Node-to-Graph.
- **Pretraining** : aucun, supervisé end-to-end.
- **Résultats clés (papier original)** : prédiction Bayley-III sur DTI bébés prématurés. **Non comparable à nous.**
- **Nous vs eux** : baseline historique de référence, réutilisée par BNT / BrainGFM sur fMRI adulte.

Swift — NeurIPS 2023

Lien : arxiv.org/abs/2307.05916

- **Architecture** : Swin Transformer 4D sur volumes fMRI directs (sans atlas). **Analogue architectural le plus proche de nous.**
- **Pretraining** : supervisé / SSL léger.
- **Résultats clés (en tant que comparator dans Brain-JEPA Table 9 et SLIM-Brain Table 1)** :
 - OASIS-3 AD Conversion : Acc 65.00 / F1 66.80
 - ADNI MCI : Acc 64.45 ± 1.69
 - ABIDE Age : Acc 62.22 ± 0.55 / MSE 0.4137 ± 0.033
 - ADHD-200 : Acc 60.81 ± 2.38
 - PPMI : Acc 58.10
 - Chiffres natifs sur HCP/ABCD/UKB Sex/Age non extraits dans ce pass.
- **Nous vs eux** : Swift < SLIM-Brain partout. Architecturalement le plus pertinent pour notre setup.

Datasets de pretraining utilisés

Rang	Dataset	~# sujets	Accès	Utilisé par
1	UK Biobank	40 000+	DUA payant	BrainLM, Brain-JEPA, SwiFT, BrainGFM
2	HCP-YA	1 200	open + DUA	BrainLM, SwiFT, LCM, nous
3	HCP-Aging	700	NDA	Brain-JEPA, LCM
4	ABCD	12 000	NDA	BNT, SwiFT, BrainGFM
5	ADNI	hundreds	DUA	downstream — Brain-JEPA, LCM, OViTAD, nous
6	ABIDE	~1 000	open	BNT, LCM, BrainGFM
7	PPMI	hundreds	DUA	LCM, BrainGFM

Observation clé : tous les SOTA au-dessus de nous pretrain sur UK Biobank (40 k+ sujets). Nous, HCP-YA seul (1.2 k, 30x moins). C'est probablement la principale source du gap.

Où on en est — synthèse en 5 lignes (Acc / F1)

1. **HCP Sex** — Nous **Acc 76.9% / F1 73.0% (C)**. SLIM-Brain **Acc 91.1% / F1 91.1%** (au-dessus de 14 points). Brain-JEPA HCPA **Acc 81.5% / F1 84.3%** (au-dessus de 5 points). **LCM HCPYA F1 72.2** $\approx$ nous (au niveau de LCM).
2. **ADNI NC vs AD** (CDR_NC_vs_AD chez nous, AD chez eux) — Nous **Acc 70.8% / F1 0.0** (threshold collapse). LCM **F1 85.3**. Brain-JEPA ne split pas. On est compétitifs en Acc mais le F1 0 nous tue dans la comparaison.
3. **ADNI NC vs MCI** — Nous **Acc 61.1% / F1 75.9** (ici F1 élevé parce que MCI est majoritaire dans le subset). Brain-JEPA **Acc 76.84% / F1 86.32**. SLIM-Brain **Acc 69.12%**. Gap ~8-16 points sur Acc.
4. **ADNI Age (régression)** — Nous **MAE 5.19 années**. Aucun SOTA n'a publié de MAE en années comparable (BrainLM en z-score uniquement). **Niche**.
5. **Degradation / AD conversion** — Nous **Deg1Y Acc 81.6% / F1 0.0**. Brain-JEPA OASIS-3 AD Conversion **Acc 69.0% / F1 67.3%**. On a plus d'Acc qu'eux MAIS leur F1 67 vs notre 0 $\square$ ils prédisent vraiment des conversions, nous on colle à la classe majoritaire.

Les 3 messages pour le meeting

1. **Scale n'est PAS tout**. Brain-JEPA et BrainLM pretrain sur UKB 32 k+. **SLIM-Brain démontre que 4 k sessions suffisent pour battre 32 k** si l'architecture est bonne (4D Hiera-JEPA, comme nous). On est à 1.2 k. **Levier #1 : améliorer l'architecture vers Hiera-JEPA, pas juste empiler de la data**.
2. **NC-vs-AD marche, NC-vs-MCI non**. Notre Acc 70.8% sur NC-vs-AD (drop MCI) est dans la zone de Brain-JEPA. Sur NC-vs-MCI on plafonne. Cohérent avec notre choix de pretraining HCP-YA (jeunes sains, zéro signal prodromal).
3. **Problème de threshold à régler**. Nos F1 = 0 sur CDR_NC_vs_AD / FAQ / Dégradation viennent du LogReg(C=1.0) sans `class_weight="balanced"` qui prédit la classe majoritaire. La même chose se produit probablement chez les SOTA mais ils ne le rapportent pas. À ajouter pour la prochaine version : probe avec `class_weight balanced + threshold tuning`, pour produire des F1 non-nuls comparables.

Les 3 SOTA à comparer en priorité (et pourquoi)

Parmi les 9 papiers passés en revue, ces 3 sont les seuls pertinents pour se positionner. Les autres sont écartés en bas de section.

#1 — SLIM-Brain (le plus pertinent)

- **Pourquoi prioritaire** : 4D Hiera-JEPA sur volumes fMRI = exactement notre paradigme. Pretraining à échelle modeste (4 129 sessions vs nos 1 200 $\square$ moins éloigné qu'UKB 32 k). Rapporte HCP Sex + ADNI

MCI + ABIDE Age, tâches comparables aux nôtres.

- **Comparaison directe** (Acc / F1) :
 - HCP Sex : eux **91.1 / 91.1** vs nous **76.9 / 73.0 (C)** — gap 14 pts Acc, 18 pts F1
 - ADNI MCI : eux **69.12 / N/A** vs nous CDR_Binary **61.0 / 0.6** — gap 8 pts Acc
- **Message thèse central** : SLIM-Brain **bat Brain-JEPA avec 8x moins de pretraining** (4 k vs 32 k sessions). C'est la **preuve** que l'**architecture > scale**, et ça valide notre direction (volumétrie + Hiera-JEPA).

#2 — Brain-JEPA (le plus comprehensive sur ADNI)

- **Pourquoi prioritaire** : seul papier qui rapporte **simultanément** Sex (HCPA), NC/MCI (ADNI), Amyloid (ADNI), et **AD Conversion** sur OASIS-3 — la **vraie comparator** pour notre Degradeation.
- **Comparaison directe** (Acc / F1) :
 - HCPA Sex : eux **81.52 / 84.26** vs nous HCP Sex **76.9 / 73.0 (C)** — gap 5 pts Acc, 11 pts F1
 - ADNI NC/MCI : eux **76.84 / 86.32** vs nous CDR_NC_vs_MCI **61.1 / 75.9** — gap 16 pts Acc, 10 pts F1
 - OASIS-3 AD Conversion : eux **69.0 / 67.3** vs nous Degradeation 1Y **81.6 / 0.0** — on a plus d'Acc, mais F1 = 0 (threshold collapse)

#3 — SwiFT (la baseline architecturale honnête)

- **Pourquoi prioritaire** : **Swin Transformer 4D sur volumes** = l'archi la plus proche de la nôtre, mais en mode supervisé (sans pretraining SSL). Sert de **baseline minimale à dépasser** pour justifier qu'on fait du SSL.
- **Comparaison directe** (Acc / F1, chiffres comme comparator dans Brain-JEPA T9 + SLIM-Brain T1) :
 - OASIS-3 AD Conversion : eux **65.0 / 66.8** vs nous Deg1Y **81.6 / 0.0** — Acc supérieure mais F1 nul
 - ADNI MCI : eux **64.45** vs nous CDR_Binary **61.0** — gap 3 pts Acc
 - ABIDE Age (cls) : eux **62.22** — pas testé chez nous
- **Message** : on est censés battre SwiFT grâce au pretraining DINOv2. Sur Acc on y arrive partiellement (Deg1Y 81.6 > 65), sur F1 on a un problème de threshold à régler.

Les 6 autres papiers, pourquoi écartés

Papier	Raison
BrainLM	Rapporte uniquement MSE z-scoré sur Age/PTSD/Anxiety — aucun chiffre Sex/MCI/AD comparable
LCM	Connectome FC matrix — paradigme totalement différent du nôtre
BNT	Graphes de connectome — pas comparable au volumétrie
OViTAD	2D slices supervisé, test n=31 (variance $\sigma=0.02$ = bruit massif)
BrainNetCNN	Préterm DTI à l'origine, baseline historique
BrainGFM	Graphes multi-atlas, chiffres précis pas extraits dans nos passes

La position à tenir en réunion

“Mon comparator principal est **SLIM-Brain** parce qu'il valide ma direction (volume + Hiera-JEPA, scale modeste). Je suis en dessous d'eux sur HCP Sex (Acc 76.9 vs 91.1) et ADNI MCI (Acc 61.0 vs 69.1), mais attendu vu qu'ils ont l'architecture aboutie et 3x plus de pretraining. Sur **AD Conversion**, je suis devant **Brain-JEPA** en Acc (81.6 vs 69.0) mais mon F1 = 0 (problème de threshold à régler avec class_weight='balanced'). Mon **angle original** c'est le split par horizon 1Y/2Y/3Y que personne ne fait. **SwiFT** est ma baseline minimale et je suis devant lui sur Acc.”