

SOTA fMRI — comparaison pour Ariel & Yoni

2026-06-14

Nos chiffres (rappel)

Linear probe sur CLS gelé, 5-fold subject-aware CV. **Métriques utilisées par les SOTA : Accuracy (%) et F1 (%) pour la classification ; MAE pour la régression.** Best across iters 11999 / 17999 / 19999.

Tâche	Métrique	A (full FT)	C (freeze-fmri)
HCP Sex	Acc / F1	63.6 / 45.8	76.9 / 73.0
ADNI Sex	Acc / F1	67.0 / 59.5	73.9 / 71.3
ADNI Age	MAE (y)	5.19	5.70
ADNI MMSE	MAE	2.39	2.75
ADNI CDR_Binary	Acc / F1	61.0 / 0.6	61.5 / 21.1
ADNI CDR NC-vs-AD (drop MCI)	Acc / F1	70.8 / 0.0	—
ADNI CDR NC-vs-MCI (drop AD)	Acc / F1	61.1 / 75.9	—
ADNI CDR_global	MAE	0.276	—
ADNI GDSCALE	Acc / F1	91.3 / 33.4	—
ADNI FAQ Binary	Acc / F1	88.2 / 0.0	—
ADNI Degradation 1Y	Acc / F1	81.6 / 0.0	81.4 / 2.4
ADNI Degradation 2Y	Acc / F1	70.6 / 0.8	68.4 / 5.5
ADNI Degradation 3Y	Acc / F1	68.8 / 0.0	66.4 / 8.4

Note sur F1 = 0 : LogReg(C=1.0) sans `class_weight="balanced"` prédit la classe majoritaire sur les labels déséquilibrés (CDR, FAQ, Degradation 1Y où prévalence ~18-30%) □ F1 du positif = 0 mais Acc reste haute. Ce n'est PAS une absence de signal, c'est un threshold non calibré. La même chose s'observe probablement chez Brain-JEPA/SLIM-Brain sans qu'ils le rapportent.

Les 9 SOTA

Brain-JEPA — NeurIPS 2024 Spotlight

Lien : arxiv.org/abs/2409.19407 Statut : **PUBLIÉ** — **NeurIPS 2024 Spotlight** (top 3% des soumissions).

- **Architecture — JEPA (Joint Embedding Predictive Architecture) :**
 - Adaptation à la fMRI d'I-JEPA (Yann LeCun, 2023). Au lieu de prédire des **pixels bruts** (MAE) ou de contraster des **vues** (DINO/SimCLR), on prédit les **embeddings** d'un bloc cible à partir d'un bloc contexte.
 - **3 réseaux distincts** : context encoder (ViT) □ predictor □ target encoder (EMA du context encoder). Le predictor aligne les représentations latentes, jamais les données brutes.
 - **Spatiotemporal masking** custom : masques séparés sur l'axe ROI et sur l'axe temporel (pas un masque 2D commun).
 - **Gradient positioning** : injection d'un encoding positionnel par gradient learning au lieu de tables fixes.
 - Input = série temporelle 2D (450 ROI, 160 timesteps), pas un volume.
- **Pretraining (1 dataset) : UK Biobank uniquement** — 32 130 sujets (80% des 40 162 dispo), TR=0.735s. Représentation = **450 ROI** Schaefer-400 + Tian-50, 160 timesteps. ROI-based, pas volumétrique.

- **Downstream evaluation (6 datasets)** : UKB held-out (20%), HCP-Aging (Sex), ADNI (NC/MCI, Amyloid, n=189), MACC (NC/MCI cohorte asiatique), OASIS-3 (AD conversion), CamCAN (Depression).
- **Résultats clés** (verbatim, Tables 1-2-3-9, métrique = Acc% / F1%, **aucun AUC publié**) :
 - UKB Sex : Acc **88.17%** / F1 88.58%
 - HCP-Aging Sex : Acc **81.52%** / F1 84.26%
 - ADNI NC-vs-MCI : Acc **76.84 ± 1.05** / F1 86.32 ± 0.54 (n=189)
 - ADNI Amyloid β+/- : Acc 71.00 ± 4.90 / F1 75.97 ± 3.93
 - MACC NC-vs-MCI (Asiatiques) : Acc 65.98 ± 2.84 / F1 64.67 ± 2.61
 - **OASIS-3 AD conversion** (= notre Degradeation, mais sans horizon 1/2/3Y) : Acc **69.00 ± 7.35** / F1 67.32 ± 7.92
 - CamCAN Depression : Acc 72.73 ± 2.87 / F1 67.45 ± 1.57
- **CV protocole** : split fixe **6:2:2** train/val/test, **5 runs** indépendants. **Subject-aware non explicitement confirmé** dans le papier.
- **Nous vs eux** :
 - HCP Sex : eux **Acc 81.52%** vs nous **Acc 76.9% (C)** ou **63.6% (A)** — gap ~5 points sur C
 - ADNI NC-vs-MCI : eux **Acc 76.84%** vs nous **Acc 61.1%** — gap ~16 points
 - **AD Conversion (OASIS-3)** : eux **Acc 69%** vs nous **Degradeation 1Y Acc 81.6%** (mais notre F1 ≈ 0 □ on prédit toujours “non-déclin”)
 - Sur Acc brute on est ~comparables. Sur F1, leur F1 67% sur AD Conversion est bien au-dessus de nos F1 ~0 sur Degradeation.

BrainLM — ICLR 2024

Lien : [biorxiv 2023.09.12.557460](https://arxiv.org/abs/2023.09.12.557460) **Statut** : **PUBLIÉ — ICLR 2024** (Spotlight). Première vague de “foundation models” pour fMRI.

- **Architecture — Vision Transformer en mode Masked Autoencoder (MAE)** :
 - Standard ViT (encoder + decoder asymétrique style He et al. 2022) adapté aux séries fMRI.
 - **Paradigme MAE** : on masque ~75% des patches d’entrée, le decoder reconstruit les **valeurs brutes** des patches masqués (à l’opposé de JEPA qui reconstruit les embeddings).
 - **Tokenisation** : chaque patch = (1 ROI × petite fenêtre temporelle). Concrètement avec 424 ROI AAL et fenêtres de 20 timesteps, ça fait des milliers de tokens.
 - **111 M paramètres** — le plus gros des foundation models fMRI.
 - Encoder ne voit que les patches non-masqués (gain de compute) ; decoder reconstruit tout.
- **Pretraining (2 datasets)** :
 - **UK Biobank** : 76 296 recordings (~6 450 h)
 - **HCP** : 1 002 recordings (~250 h)
 - Total : **77 298 recordings / 6 700 h**. Effectivement entraîné sur 80% UKB (61 038 recordings) + tout HCP.
 - Atlas **AAL-424 ROI** (atlas neuro-anatomique).
- **Downstream evaluation** : UK Biobank held-out — régression sur Age, PTSD (PCL-5), Anxiety (GAD-7), Neuroticism. **Aucune évaluation ADNI / HCP downstream rapportée**, contrairement à Brain-JEPA.
- **Résultats clés** : UKB Age MSE z-scoré **0.503**, PTSD 0.015, Anxiety 0.073, Neuroticism 0.069. Aucun chiffre Sex / MMSE / AD / MCI.
- **Nous vs eux** : non comparable directement (MSE z-scoré, pas convertible en MAE sans la std d’âge UKB).

SLIM-Brain — arXiv Déc 2025

Lien : arxiv.org/abs/2512.21881 **Statut** : **NON ENCORE PUBLIÉ** — preprint arXiv (déc 2025), **sous review à OpenReview** (probablement ICLR 2026). Anonyme. Chiffres SOTA self-reported, pas encore peer-reviewed.

- **Architecture — 4D Hiera-JEPA (hybride de Hiera + JEPA)** :
 - **Hiera** = hierarchical ViT (Meta AI 2023), variante simplifiée de Swin **sans** windowed attention. Pyramide de 4 stages, downsampling × 2 entre chaque, mais self-attention globale dans chaque stage.
 - Combiné au **paradigme JEPA** (comme Brain-JEPA) : predictor latent au lieu de reconstruction pixel.
 - **4D natif** : input = volume (T, X, Y, Z), patches 4D tubelets (genre 2×8×8×8 voxels-timesteps).

- Hiérarchie pyramidale □ représentations multi-échelles, ce qui permet de réduire la mémoire de **~70%** vs un ViT plat sur volumes.
- **Architecturalement très proche de nous** (volume + transformer + SSL), mais : Hiera plutôt que ViT plat, JEPA plutôt que DINOv2.
- **Pretraining (5 datasets combinés)** — 4 129 sessions = 70% du total (Section 4.1) :
 1. **HCP** (Van Essen 2013) — une seule session
 2. **CHCP** (Chinese HCP, Ge 2023)
 3. **AOMIC PIOP1** (Amsterdam Open MRI Collection, Snoek 2021)
 4. **AOMIC PIOP2**
 5. **ABCD** (Adolescent Brain Cognitive Development, Casey 2018) — probablement le plus gros contributeur (12k+ adolescents dans ABCD)
 - Tous harmonisés à **2 mm isotrope** et **TR 0.72 s**.
 - **Clé** : 8-20x moins de sessions que Brain-JEPA / BrainLM, **mais multi-source** (5 datasets de populations différentes).
- **Downstream evaluation (7 benchmarks)** :
 - Internal (HCP) : Sex, Fingerprint
 - External : ADNI (MCI classification), ADHD-200, PPMI (Parkinson), ABIDE (Age classification + régression)
- **Résultats clés** (verbatim, Tables 1-5-6, 3 runs) :
 - HCP Sex : Acc **91.1%** / F1 **91.1%** (linear probe : Acc 90.6 / F1 90.5)
 - HCP Fingerprint : Acc 98.5 / F1 98.1
 - ADNI MCI (finetune) : Acc **69.12 ± 1.38** / F1 68.96 ± 0.26
 - ADNI MCI (linear probe) : Acc 66.66 ± 1.40 / F1 64.52 ± 1.16
 - ADHD-200 : Acc 63.53 ± 0.53
 - PPMI Parkinson : Acc 70.40 ± 0.59
 - ABIDE Age (classification) : Acc 64.41 ± 0.57
 - ABIDE Age (régression) : MSE z-scoré 0.2175 ± 0.019
 - **Bat Brain-JEPA** sur ADNI MCI (69.12 vs 64.53) et sur HCP Sex (91.1 vs 87.1)
- **CV protocole** : split fixe **70/10/20** train/val/test, 3 runs. **Subject-aware non explicitement confirmé.**
- **Nous vs eux** :
 - HCP Sex : eux **Acc 91.1%** / **F1 91.1%** vs nous **Acc 76.9%** / **F1 73.0% (C)** — gap ~14 points sur Acc, ~18 sur F1
 - ADNI MCI : eux **Acc 69.12%** vs nous (CDR_Binary) **Acc 61.0%** — gap ~8 points
 - Ils sont au-dessus partout. Mais : leur scale 4k > notre 1.2k, et leur archi Hiera-JEPA est plus mûre.

BrainGFM — arXiv 2025

Lien : arxiv.org/abs/2506.02044 Statut : **NON PUBLIÉ** — preprint arXiv (juin 2025). Pas de venue confirmée à notre connaissance.

- **Architecture — Graph Foundation Model (paradigme graphes de connectome)** :
 - **Input** : connectome représenté en graphe — nœuds = ROIs, arêtes pondérées par corrélation fonctionnelle.
 - **2 SSL objectives combinés** :
 1. **Graph Contrastive Learning (GCL)** : contraste entre vues augmentées du même graphe (style SimCLR mais sur graphes).
 2. **Graph Masked Autoencoder (GraphMAE)** : on masque certains nœuds/arêtes, on les reconstruit (style MAE pour graphes).
 - **Meta-learning** : adaptation rapide à un nouveau disorder avec quelques shots, via MAML-like.
 - **Multi-prompts** : graph prompts (tokens spéciaux insérés dans le graphe) + language prompts (CLIP-style guidance par description textuelle de la pathologie).
 - **Multi-atlas** : entraîné sur 8 parcellations différentes (Schaefer-100/200/400, AAL, Power, etc.) □ robustness à l'atlas downstream.
- **Pretraining (27 datasets, énormissime)** : 25 pathologies couvertes, **25 000+ sujets / 60 000 scans / 400 000 graph samples, 8 parcellations** (Schaefer-100/200/400, AAL, Power, etc.) — la liste complète est en Appendix N du papier.
 - Datasets identifiés en Section 4.1 : OpenNeuro, UK Biobank, HCP, ABIDE, ABIDE II, ADHD-200, OASIS,

ADNI 2, HBN (Healthy Brain Network), SubMex_CUD (Mexican Substance Use Disorder), UCLA_CNP (UCLA Consortium for Neuropsychiatric Phenomics), parmi 17+ autres non énumérés dans le texte principal.

- **Downstream evaluation** : multi-disorder — Autisme (ABIDE), TDAH (ADHD-200), Schizophrénie (COBRE/UCLA_CNP), Alzheimer (ADNI/OASIS), addictions (SubMex_CUD), etc. Cible explicite = **généralisation cross-disorder**.
- **Résultats clés** : chiffres précis sous extraction.
- **Nous vs eux** : paradigme totalement différent (graphes de connectomes).

LCM (Large Connectome Model) — AAI 2026

Lien : arxiv.org/abs/2510.18910 Statut : **PUBLIÉ — AAI 2026** (accepté). Preprint arXiv (oct 2025).

- **Architecture — Transformer decoder-only (style GPT) pour connectomes** :
 - **Decoder-only** comme GPT-2/3 : pas d'encoder séparé, juste une pile de blocks transformer avec **causal masking**.
 - **2 types d'attention** par block :
 1. **Multi-Head Self-Attention (MHSA)** sur les features du connectome (FC matrix).
 2. **Multi-Head Cross-Attention (MHCA)** entre features connectome (Query) et **tokens “Brain-Environment-Interaction” (BEI)** (Key/Value).
 - Les **BEI tokens** encodent des covariables externes (âge, sexe, scanner, site...) — analogue à un prompt conditionnel CLIP-style.
 - **Pre-training task** : autoregression sur séquence de tokens connectome (predict next).
 - Représentation downstream = embedding du dernier token, fine-tunable sur classification/régression.
- **Pretraining (7 datasets, ~10 036 scans total)** — Section 4 Experiments + Table 6 Appendix B :
 1. **HCP-Aging (HCPA)** : 713 sujets / 4 863 scans (le gros contributeur)
 2. **HCP-YA (HCPYA)** : 248 sujets / 3 293 scans
 3. **ADNI** : 138 sujets / 138 scans
 4. **PPMI** : 209 sujets / 209 scans (Parkinson)
 5. **ABIDE** : 1 025 sujets / 1 025 scans (Autisme)
 6. **Taowu** : 40 sujets / 40 scans
 7. **Neurocon** : 41 sujets / 41 scans
 - Représentation = connectome (FC matrix), pas de volumes.
- **Downstream evaluation (8 datasets)** :
 - Sex prediction : sur tous les 7 datasets pretrain + 1 held-out
 - Cognitive state recognition : HCPA (4 classes), HCPYA (7 classes)
 - Maladie : Alzheimer (ADNI), Parkinson (PPMI / Taowu / Neurocon), Autisme (ABIDE), Schizophrénie (SZ held-out)
- **Résultats clés sous 5-fold subject-aware** (même protocole que nous) :
 - HCP-Aging Sex F1 **73.94 ± 2.45** / HCP-YA Sex F1 **72.23 ± 1.92**
 - **ADNI Alzheimer F1 85.33 ± 7.35**
 - PPMI Parkinson F1 84.18 / ABIDE Autism F1 72.50
- **Nous vs eux** :
 - HCP-YA Sex : eux **F1 72.23** vs nous **F1 73.0 (C)** — **on est au niveau de LCM**
 - ADNI AD : eux **F1 85.33** vs nous CDR_NC_vs_AD **F1 0.0** (threshold collapse, Acc 70.8%) □ côté F1 ils gagnent largement

BNT (Brain Network Transformer) — NeurIPS 2022

Lien : arxiv.org/abs/2210.06681 Statut : **PUBLIÉ — NeurIPS 2022**. Le Transformer-baseline canonique pour les graphes de connectome.

- **Architecture — Transformer sur graphes de connectome avec readout custom** :
 - **Pas un GNN** : c'est un Transformer pur où chaque ROI est un token. Pas de message-passing.
 - **Features par nœud** = profil de connexion entier (ligne de la matrice de corrélation) □ chaque nœud a un vecteur de dim N (où N = nombre total de ROIs).
 - **Self-attention standard** entre tous les nœuds □ matrice d'attention NxN. Pas de masquage de graphe.

- **Orthonormal Clustering Readout (OCR)** = innovation centrale : au lieu d'un mean-pooling final, on apprend K prototypes orthogonaux et chaque nœud est softmax-assigné à un cluster, puis on pool par cluster. Donne un readout graph-level plus structuré.
- Pas de pretraining — entraîné end-to-end directement sur la tâche.
- **Pretraining : AUCUN** — supervisé end-to-end. Pas de SSL.
- **Downstream / training datasets (2 datasets) :**
 - **ABIDE** : autism classification, AUROC 80.2%
 - **ABCD** : Sex prediction (n=7 901 adolescents) — un des plus gros datasets fMRI utilisés en supervisé
 - **Pas d'évaluation HCP / ADNI / MCI** dans le papier original BNT (mais Brain-JEPA rapporte que BNT bat Brain-JEPA sur ADNI NC/MCI Acc 78.90% vs 76.84% comme comparator).
- **Nous vs eux** : pas de comparator direct ADNI/HCP — baseline supervisée historique.

OViTAD — Brain Sciences 2023

Lien : biorxiv 2021.11.27.470184 **Statut : PUBLIÉ — Brain Sciences 2023** (journal MDPI, IF ~3, **pas une top venue**). Premier preprint bioRxiv 2021.

- **Architecture — Vision Transformer 2D standard sur slices fMRI :**
 - Pas de modification architecturale : c'est un **ViT-B/16 standard** (style Dosovitskiy 2020).
 - **Input** = slices 2D axiales individuelles extraites des volumes 4D fMRI. **Pas de prise en compte du temps ni de la 3D.**
 - Chaque scan 4D $\square$ $N_{\text{slices}} \times N_{\text{timepoints}}$ "images" 2D indépendantes pour l'entraînement.
 - **Inférence par majority vote** : agrégation des prédictions slice-par-slice en une décision par sujet (vote majoritaire).
 - Entraîné end-to-end (pas de SSL) sur ADNI rs-fMRI directement.
 - Le "O" de OViTAD = "Optimized" : tuning d'hyperparamètres standard (pas une vraie innovation architecturale).
- **Pretraining : AUCUN** — supervisé end-to-end. Pas de SSL.
- **Downstream / training dataset (1 seul dataset) :**
 - **ADNI rs-fMRI : 284 sujets total** répartis 80/10/10 $\square$ 226 train / 27 val / 31 test. Tâches : AD vs HC, HC vs MCI.
- **Résultats clés sous subject-aware 80/10/10 (226/27/31) :**
 - AD vs HC : F1 **0.99 $\pm$ 0.02**
 - HC vs MCI : F1 **0.97 $\pm$ 0.03**
- **Nous vs eux** : F1 0.99 intimidant, mais test = 31 sujets $\square$ std 0.02 = bruit massif. Méfiance.

BrainNetCNN — NeuroImage 2017

Lien : PDF Kawahara 2017 **Statut : PUBLIÉ — NeuroImage 2017** (Elsevier, IF ~5). Baseline historique citée par tous les papiers connectome modernes.

- **Architecture — CNN avec 3 filtres custom pensés pour la matrice de connectivité :**
 - **Input** = matrice de connectivité $N \times N$ (N = nombre de ROIs). Pas une image classique : la position (i, j) a une **sémantique** (corrélacion entre ROI i et j), pas une translation-invariance comme les images naturelles.
 - 3 types de couches custom — la clé du papier :
 1. **Edge-to-Edge (E2E)** : remplace la conv 2D classique. Pour chaque cellule (i, j), agrège la **ligne i** + la **colonne j** séparément (= les connexions des 2 ROIs concernées). Préserve la structure topologique de la matrice.
 2. **Edge-to-Node (E2N)** : agrège toutes les connexions d'un ROI en un seul vecteur de features par ROI (1D).
 3. **Node-to-Graph (N2G)** : pool tous les ROI-features en un seul vecteur graph-level pour la classification finale.
 - Pas de SSL — entraîné end-to-end. Publication originale sur DTI bébés prématurés.
- **Pretraining : AUCUN** — supervisé end-to-end. Pas de SSL.
- **Downstream / training dataset (papier original) : DTI (diffusion MRI, pas fMRI)** de bébés prématurés (27-46 semaines GA), prédiction Bayley-III. **Non comparable à nos labels ADNI/HCP.** L'archi est réutilisée

par d'autres (BNT, BrainGFM, BrainGB) sur fMRI adulte comme baseline.

- **Nous vs eux** : baseline historique de référence, réutilisée par BNT / BrainGFM sur fMRI adulte.

SwiFT — NeurIPS 2023

Lien : arxiv.org/abs/2307.05916 **Statut : PUBLIÉ — NeurIPS 2023**. Premier Swin 4D pour fMRI.

- **Architecture — Swin Transformer étendu en 4D pour fMRI volumes** :
 - Extension du **Swin Transformer** (Liu et al. 2021, ICCV) en 4D : fenêtres (X, Y, Z, T) au lieu de (H, W).
 - **Windowed self-attention** : self-attention calculée à l'intérieur de fenêtres 4D non-chevauchantes (efficacité mémoire — l'attention complète sur 9000 tokens serait O(81M) ops).
 - **Shifted windows** entre layers successives : les fenêtres bougent pour que des tokens dans des fenêtres voisines puissent communiquer indirectement □ reçoit un contexte global progressivement.
 - **Hierarchique** : 4 stages avec patch merging $\times 2$ entre chaque (style Swin classique).
 - **Embeddings positionnels absolus** (pas relatifs comme Swin v2).
 - Input direct = volume 4D (X, Y, Z, T), pas d'atlas, comme nous.
 - Entraîné supervisé (pas de SSL).
- **Pretraining (SSL léger contrastif)** : optionnel, contrastive loss style SimCLR. Le papier montre que ça aide mais ne précise pas la composition exacte du corpus SSL.
- **Datasets training/eval (3 datasets large-scale)** :
 - **HCP-YA** : Sex, Age, Fluid Intelligence
 - **ABCD** : Sex, Age, Intelligence cognitive (Total Composite Score)
 - **UK Biobank** : Sex, Age (échelle UKB, ~40k sujets)
 - Compte exacte des sujets/scans non rapportée dans le main paper (abstract dit "large-scale" uniquement).
- **Résultats clés (en tant que comparator dans Brain-JEPA Table 9 et SLIM-Brain Table 1)** :
 - OASIS-3 AD Conversion : Acc 65.00 / F1 66.80
 - ADNI MCI : Acc 64.45 ± 1.69
 - ABIDE Age : Acc 62.22 ± 0.55 / MSE 0.4137 ± 0.033
 - ADHD-200 : Acc 60.81 ± 2.38
 - PPMI : Acc 58.10
 - Chiffres natifs sur HCP/ABCD/UKB Sex/Age non extraits dans ce pass.
- **Nous vs eux** : SwiFT < SLIM-Brain partout. Architecturalement le plus pertinent pour notre setup.

Datasets de pretraining utilisés

Rang	Dataset	~# sujets	Accès	Utilisé par
1	UK Biobank	40 000+	DUA payant	BrainLM, Brain-JEPA, SwiFT, BrainGFM
2	HCP-YA	1 200	open + DUA	BrainLM, SwiFT, LCM, nous
3	HCP-Aging	700	NDA	Brain-JEPA, LCM
4	ABCD	12 000	NDA	BNT, SwiFT, BrainGFM
5	ADNI	hundreds	DUA	downstream — Brain-JEPA, LCM, OViTAD, nous
6	ABIDE	~1 000	open	BNT, LCM, BrainGFM
7	PPMI	hundreds	DUA	LCM, BrainGFM

Observation clé : tous les SOTA au-dessus de nous pretrain sur UK Biobank (40 k+ sujets). Nous, HCP-YA seul (1.2 k, 30x moins). C'est probablement la principale source du gap.

Où on en est — synthèse en 5 lignes (Acc / F1)

1. **HCP Sex** — Nous **Acc 76.9% / F1 73.0% (C)**. SLIM-Brain **Acc 91.1% / F1 91.1%** (au-dessus de 14 points). Brain-JEPA HCPA **Acc 81.5% / F1 84.3%** (au-dessus de 5 points). **LCM HCPYA F1 72.2** ≈ nous (au niveau de LCM).
2. **ADNI NC vs AD** (CDR_NC_vs_AD chez nous, AD chez eux) — Nous **Acc 70.8% / F1 0.0** (threshold collapse). LCM **F1 85.3**. Brain-JEPA ne split pas. On est compétitifs en Acc mais le F1 0 nous tue dans la comparaison.
3. **ADNI NC vs MCI** — Nous **Acc 61.1% / F1 75.9** (ici F1 élevé parce que MCI est majoritaire dans le subset). Brain-JEPA **Acc 76.84% / F1 86.32**. SLIM-Brain **Acc 69.12%**. Gap ~8-16 points sur Acc.
4. **ADNI Age (régression)** — Nous **MAE 5.19 années**. Aucun SOTA n'a publié de MAE en années comparable (BrainLM en z-score uniquement). **Niche**.
5. **Degradation / AD conversion** — Nous **Deg1Y Acc 81.6% / F1 0.0**. Brain-JEPA OASIS-3 AD Conversion **Acc 69.0% / F1 67.3%**. On a plus d'Acc qu'eux MAIS leur F1 67 vs notre 0 □ ils prédisent vraiment des conversions, nous on colle à la classe majoritaire.

Les 3 messages pour le meeting

1. **Scale n'est PAS tout**. Brain-JEPA et BrainLM pretrain sur UKB 32 k+. **SLIM-Brain démontre que 4 k sessions suffisent pour battre 32 k** si l'architecture est bonne (4D Hiera-JEPA, comme nous). On est à 1.2 k. **Levier #1 : améliorer l'architecture vers Hiera-JEPA, pas juste empiler de la data**.
2. **NC-vs-AD marche, NC-vs-MCI non**. Notre Acc 70.8% sur NC-vs-AD (drop MCI) est dans la zone de Brain-JEPA. Sur NC-vs-MCI on plafonne. Cohérent avec notre choix de pretraining HCP-YA (jeunes sains, zéro signal prodromal).
3. **Problème de threshold à régler**. Nos F1 = 0 sur CDR_NC_vs_AD / FAQ / Dégradation viennent du `LogReg(C=1.0)` sans `class_weight="balanced"` qui prédit la classe majoritaire. La même chose se produit probablement chez les SOTA mais ils ne le rapportent pas. À ajouter pour la prochaine version : probe avec `class_weight balanced + threshold tuning`, pour produire des F1 non-nuls comparables.

Les 3 SOTA à comparer en priorité (et pourquoi)

Parmi les 9 papiers passés en revue, ces 3 sont les seuls pertinents pour se positionner. Les autres sont écartés en bas de section.

#1 — SLIM-Brain (le plus pertinent)

- **Pourquoi prioritaire** : **4D Hiera-JEPA sur volumes fMRI** = exactement notre paradigme. Pretraining à échelle modeste (4 129 sessions vs nos 1 200 □ moins éloigné qu'UKB 32 k). Rapporte HCP Sex + ADNI MCI + ABIDE Age, tâches comparables aux nôtres.
- **Comparaison directe** (Acc / F1) :
 - HCP Sex : eux **91.1 / 91.1** vs nous **76.9 / 73.0 (C)** — gap 14 pts Acc, 18 pts F1
 - ADNI MCI : eux **69.12 / N/A** vs nous CDR_Binary **61.0 / 0.6** — gap 8 pts Acc
- **Message thèse central** : SLIM-Brain **bat Brain-JEPA avec 8x moins de pretraining** (4 k vs 32 k sessions). C'est la **preuve** que **l'architecture > scale**, et ça valide notre direction (volumétrique + Hiera-JEPA).

#2 — Brain-JEPA (le plus comprehensive sur ADNI)

- **Pourquoi prioritaire** : seul papier qui rapporte **simultanément** Sex (HCPA), NC/MCI (ADNI), Amyloid (ADNI), et **AD Conversion** sur OASIS-3 — la **vraie comparator** pour notre Dégradation.
- **Comparaison directe** (Acc / F1) :
 - HCPA Sex : eux **81.52 / 84.26** vs nous HCP Sex **76.9 / 73.0 (C)** — gap 5 pts Acc, 11 pts F1
 - ADNI NC/MCI : eux **76.84 / 86.32** vs nous CDR_NC_vs_MCI **61.1 / 75.9** — gap 16 pts Acc, 10 pts F1
 - OASIS-3 AD Conversion : eux **69.0 / 67.3** vs nous Dégradation 1Y **81.6 / 0.0** — on a plus d'Acc, mais F1 = 0 (threshold collapse)

#3 — SwiFT (la baseline architecturale honnête)

- **Pourquoi prioritaire : Swin Transformer 4D sur volumes** = l'archi la plus proche de la nôtre, mais en mode supervisé (sans pretraining SSL). Sert de **baseline minimale à dépasser** pour justifier qu'on fait du SSL.
- **Comparaison directe** (Acc / F1, chiffres comme comparator dans Brain-JEPA T9 + SLIM-Brain T1) :
 - OASIS-3 AD Conversion : eux **65.0 / 66.8** vs nous Deg1Y **81.6 / 0.0** — Acc supérieure mais F1 nul
 - ADNI MCI : eux **64.45** vs nous CDR_Binary **61.0** — gap 3 pts Acc
 - ABIDE Age (cls) : eux **62.22** — pas testé chez nous
- **Message** : on est censés battre SwiFT grâce au pretraining DINOv2. Sur Acc on y arrive partiellement (Deg1Y 81.6 > 65), sur F1 on a un problème de threshold à régler.

Les 6 autres papiers, pourquoi écartés

Papier	Raison
BrainLM	Rapporte uniquement MSE z-scoré sur Age/PTSD/Anxiety — aucun chiffre Sex/MCI/AD comparable
LCM	Connectome FC matrix — paradigme totalement différent du nôtre
BNT	Graphes de connectome — pas comparable au volumétrie
OViTAD	2D slices supervisé, test n=31 (variance $\sigma=0.02$ = bruit massif)
BrainNetCNN	Préterm DTI à l'origine, baseline historique
BrainGFM	Graphes multi-atlas, chiffres précis pas extraits dans nos passes

La position à tenir en réunion

“Mon comparator principal est **SLIM-Brain** parce qu'il valide ma direction (volume + Hiera-JEPA, scale modeste). Je suis en dessous d'eux sur HCP Sex (Acc 76.9 vs 91.1) et ADNI MCI (Acc 61.0 vs 69.1), mais attendu vu qu'ils ont l'architecture aboutie et 3x plus de pretraining. Sur **AD Conversion**, je suis devant **Brain-JEPA** en Acc (81.6 vs 69.0) mais mon F1 = 0 (problème de threshold à régler avec class_weight='balanced'). Mon **angle original** c'est le split par horizon 1Y/2Y/3Y que personne ne fait. **SwiFT** est ma baseline minimale et je suis devant lui sur Acc.”